

Futbolcu Piyasa Değerinin Makine Öğrenmesi Yöntemleriyle Tahmini

Grup 2 - Proje Ekibi:

210229020 Yavuz Selim Çoraklı

210229033 Miran Emre Eser

210229041 İrem Çelebi

Özet

Bu çalışmada, futbol transfer piyasasında oyuncu değerlemelerinin büyük ölçüde öznel gözlemlere dayanması ve bunun kulüpler için yarattığı finansal belirsizlik problemi ele alınmıştır. Çalışmanın amacı, futbolcuların demografik özellikleri, saha içi performans istatistikleri ve bulundukları lig ekosisteminin ekonomik değerleri üzerindeki etkisini nicel yöntemlerle ortaya koymak ve veri odaklı bir piyasa değeri tahmin modeli geliştirmektir. Transfermarkt kaynaklı, Kaggle üzerinden erişilen ham veri kümeleri (yaklaşık 47.700 oyuncu, 1,8 milyon maç kaydı) birleştirilmiş, temizlenmiş ve modellemeye uygun hâle getirilmiştir. Hedef değişken olan piyasa değeri sürekli bir nicelik olduğundan problem bir regresyon problemi olarak kurgulanmış; Lineer Regresyon ve Random Forest algoritmaları hem genel hem de mevki bazlı olarak eğitilip karşılaştırılmıştır. Random Forest modeli, genel veri kümesinde doğrusal modele belirgin üstünlük sağlamıştır. Özellik önemi analizine göre oyuncu değerini en güçlü açıklayan değişkenler yaş, toplam maç sayısı ve oyuncunun bulunduğu lig olmuştur. Ayrıca eğitilen modeller serileştirilerek, kullanıcıların oyuncu özelliklerini girip anlık piyasa değeri tahmini alabildiği etkileşimli bir Streamlit arayüzü geliştirilmiştir.

1. Problem Tanımı ve Hedef Belirleme

Modern futbol endüstrisinde oyuncu transferleri, kulüplerin bütçelerini doğrudan etkileyen yüksek tutarlı finansal kararlardır. Buna karşın transfer piyasasındaki değerlemeler çoğu zaman sistematik veriden ziyade gözleme, sezgiye ve piyasa beklentilerine dayanmaktadır. Bu öznellik, kulüpler açısından bir oyuncuya gereğinden fazla ödeme yapma ya da değerli bir oyuncuyu düşük bedelle elden çıkarma gibi ölçülebilir finansal risklere yol açmaktadır. Bu çalışmada tanımlanan problem, bir futbolcunun ölçülebilir nitelikleri ile güncel piyasa değeri arasındaki ilişkinin nicel olarak modellenebilirliğidir.

Projenin temel amacı, futbolcuların yaş, boy, uyrak gibi verilerinin, saha içi performans istatistiklerinin ve oynadıkları lig ile mevkinin piyasa değeri üzerindeki etkisini veriye dayalı yöntemlerle açıklamak ve bu değişkenler aracılığıyla piyasa değerini tahmin eden bir model geliştirmektir. Kapsam, aktif transfer piyasasını temsil eden futbolcularla sınırlandırılmıştır; bu

doğrultuda emekliliğe yakın oyuncular ile düşük piyasa değerine sahip oyuncular analiz dışında bırakılmıştır.

Çalışmanın yanıt aradığı temel araştırma sorusu şu şekilde ifade edilebilir: “Bir futbolcunun verileri kullanılarak güncel piyasa değeri ne ölçüde doğru tahmin edilebilir?” Hedef değişken olan piyasa değeri (market_value_in_eur) sürekli ve sayısal bir büyüklük olduğundan, problem denetimli öğrenme altında bir regresyon problemi olarak ele alınmıştır. Sınıflandırma yerine regresyonun seçilmesinin sebebi, çıktının kategorik bir etiket değil, Euro cinsinden sürekli bir miktar olmasıdır. Hedef değişkenin oldukça sağa çarpık bir dağılıma sahip olması nedeniyle, modellemede ham değer yerine logaritmik dönüşümü uygulanmış (log_market_value) ve böylece dağılımın normalleştirilmesi amaçlanmıştır.

2. Veri Toplama

Çalışmada veri kümesi olarak “Football Data from Transfermarkt” veri seti kullanılmıştır. Analizde, birbiriyle ilişkilendirilmek üzere beş ayrı tablo kullanılmıştır.

- **players.csv:** oyuncuların demografik bilgileri (yaş, boy, uyruk, mevki, ayak tercihi).
- **player_valuations.csv:** oyuncuların tarihsel piyasa değeri kayıtları; her oyuncu için en güncel değer alınmıştır.
- **appearances.csv:** maç bazında performans istatistikleri (gol, asist, oynanan süre, kartlar).
- **competitions.csv:** lig/turnuva bilgileri.
- **clubs.csv:** kulüp bilgileri.

3. Veri Anlama ve Keşifsel Analiz

Ham tablolar, hem satır sayısı hem de değişken çeşitliliği bakımından büyük ölçeklidir. Aşağıdaki tabloda her bir kaynak tablonun boyutu özetlenmiştir.

Tablo	Satır Sayısı	Sütun Sayısı
players.csv	47.702	26
player_valuations.csv	616.377	6
appearances.csv	1.862.208	13
competitions.csv	67	11
clubs.csv	796	17

Performans tablosu maç düzeyinde tutulduğundan, oyuncu başına analiz yapabilmek için appearances tablosu player_id alanı üzerinden gruplandırılmış; her oyuncu için toplam gol, toplam asist, toplam dakika, toplam maç sayısı ile sarı ve kırmızı kart toplamaları hesaplanmıştır. Ayrıca maç başına gol (goals_per_match), maç başına asist (assists_per_match) ve maç başına

dakika (minutes_per_match) gibi oransal türetilmiş değişkenler oluşturulmuştur. En güncel piyasa değeri ise valuations tablosu tarihe göre sıralanıp her oyuncu için son kayıt seçilerek elde edilmiştir.

Tablolar player_id anahtarı üzerinden birleştirildiğinde, oyuncu sayısı 47.702'den 39.226'ya gerilemiştir; bu azalma, piyasa değeri kaydı bulunmayan oyuncuların elenmesinden kaynaklanmaktadır. Birleştirme sonrası incelemede 11.585 oyuncunun hiçbir maç istatistiğine sahip olmadığı tespit edilmiş ve bu gözlemlerin ön işleme aşamasında çıkarılmasına karar verilmiştir. Eksik veri analizinde boy (height_in_cm), ayak tercihi (foot), uyruk ve kulüp lig bilgisi gibi alanlarda da boşluklar gözlemlenmiştir. Temel istatistiksel inceleme (describe) ve görselleştirmeler aracılığıyla piyasa değerinin güçlü biçimde sağa çarpık olduğu; oyuncuların büyük çoğunluğunun 0–25 milyon € aralığında yoğunlaştığı, az sayıda oyuncunun ise çok yüksek değerlere ulaştığı saptanmıştır. Bu bulgu, hedef değişkene logaritmik dönüşüm uygulanması kararını gerekçelendirmiştir.

4. Veri Ön İşleme

4.1. Eksik Veri İşlemleri

Öncelikle gol, asist, toplam dakika ve yaş alanlarında eksik değere sahip oyuncular (maç istatistiği bulunmayan 11.585 kayıt) veri kümesinden çıkarılmıştır; bu işlem, modelin yalnızca performans verisi mevcut oyuncular üzerinde öğrenmesini sağlamak amacıyla tercih edilmiştir. Kalan eksik değerler ise değişkenin niteliğine uygun stratejilerle doldurulmuştur: ayak tercihi, uyruk ve lig bilgisi gibi kategorik alanlardaki boşluklar “unknown” etiketiyle, sayısal bir değişken olan boy ise sütun ortalamasıyla tamamlanmıştır. Alt mevki (sub_position) bilgisi eksik olan kayıtlarda ilgili oyuncunun genel mevkiisi atanmıştır. Ayrıca “Missing” değerine sahip geçersiz mevki kayıtları elenmiştir.

4.2. Aykırı Değer Yönetimi

Fiziksel ve mantıksal olarak tutarsız gözlemler, kural tabanlı eşikler aracılığıyla temizlenmiştir. Boyu 150 cm'nin altında olan 3 oyuncu ile yaşı 45'in üzerinde bulunan 603 oyuncu aykırı kabul edilerek çıkarılmıştır; yaş için 15–45 aralığı geçerli sınır olarak belirlenmiştir.

4.3. Kapsam Filtreleme

Modelin aktif transfer piyasasını temsil etmesi amacıyla iki kapsam filtresi uygulanmıştır. İlk olarak, kariyerlerinin sonuna yaklaşmış ve transfer piyasasında etkinliği azalmış kabul edilen 38 yaş ve üstü oyuncular çıkarılmıştır. İkinci olarak, gerçek piyasa dinamiklerini yansıtmadığı değerlendirilen, 100.000 € altı değere sahip oyuncular elenmiştir.

4.4. Özellik Dönüşümü ve Türetme

Hedef değişkenin sağa çarpık dağılımını gidermek üzere piyasa değerine log1p dönüşümü uygulanarak log_market_value değişkeni türetilmiştir. Keşifsel analizde toplam oynanan süre

(total_minutes) ile toplam maç sayısı (total_matches) arasında 0,98 düzeyinde çok yüksek bir korelasyon belirlenmiştir. Bu durum çoklu doğrusal bağlantı (multicollinearity) riski oluşturduğundan, total_minutes değişkeni modelden çıkarılmıştır. Önceki aşamada üretilen maç başına gol, asist ve dakika gibi oransal değişkenler ise toplam değerlerin yanında oyuncu verimliliğini normalize ederek temsil etmek üzere korunmuştur.

4.5. Kategorik Kodlama


Mevki (position), alt mevki (sub_position), ayak tercihi (foot), uyruk (country_of_citizenship) ve lig (player_club_domestic_competition_id) gibi kategorik değişkenler, makine öğrenmesi algoritmalarının işleyebileceği sayısal biçime dönüştürülmüştür. Bu amaçla Etiket Kodlaması (Label Encoding) kullanılmış ve her kategorik değişken için “_encoded” son ekli yeni bir sayısal sütun üretilmiştir. Özellikle uyruk ve lig gibi çok sayıda kategori içeren değişkenlerde, One-Hot kodlamanın yaratacağı yüksek boyutluluğun önüne geçmek için etiket kodlaması tercih edilmiştir.

4.6. Ölçekleme ve Özellik Seçimi

Sürekli sayısal değişkenler (yaş, boy, toplam gol/asist/maç, kartlar ve maç başına oranlar) StandardScaler ile standartlaştırılmış; böylece her değişken ortalaması sıfır, standart sapması bir olacak biçimde ölçeklenmiştir. Bu işlem, özellikle uzaklık ve katsayı temelli yorumlarda değişkenlerin ortak bir ölçek üzerinde değerlendirilmesini sağlamaktadır. Son olarak modelleme için anlamsız ya da kodlanmış karşılığı bulunan ham sütunlar (player_id, kodlanmamış kategorik metin alanları ve ham market_value_in_eur) düşürülmüştür. Ön işleme sürecinin sonunda 20.025 futbolcu ve 17 değişkenden oluşan, yeniden çalıştırılabilir bir işlenmiş veri kümesi (processed.csv) elde edilmiştir.


4.7. Grafikler

Piyasa değeri dağılımı grafiği, hedef değişkenin ham hâlinin güçlü biçimde sağa çarpık olduğunu; logaritmik dönüşüm sonrası ise dağılımın normale çok daha yakın, simetrik bir biçim aldığını göstermektedir. Bu görsel, log dönüşümü kararının ardındaki temel gerekçeyi görsel olarak doğrulamaktadır.




Grafik 1: Piyasa değerinin ham ve logaritmik dağılımı.

Yaş–piyasa değeri ilişkisi grafiği, piyasa değerinin yaklaşık 25–28 yaş aralığında zirveye ulaştığını ve sonrasında yaşla birlikte düşme eğilimine girdiğini ortaya koymaktadır. Bu eğilim, yaş ile piyasa değeri arasında hesaplanan zayıf negatif korelasyon ($-0,15$) ile uyumludur.




Grafik 2: Yaş ile piyasa değeri (log) arasındaki ilişki.

Pozisyona göre medyan piyasa değeri grafiği, mevkiler arasında çarpıcı bir değer farkı bulunmadığını; ancak kalecilerin diğer mevkilere kıyasla görece daha düşük bir medyan değere sahip olduğunu göstermektedir.



Grafik 3: Pozisyona göre medyan piyasa değeri.

Korelasyon ısı haritası, sayısal değişkenler arasındaki ilişkileri özetlemektedir. Bu görselde toplam süre ile toplam maç sayısı arasındaki 0,98 düzeyindeki çok güçlü ilişki açıkça görülmekte olup, bu bulgu çoklu doğrusal bağlantıyı önlemek için total_minutes değişkeninin çıkarılması kararını gerekçelendirmiştir.



Grafik 4: Sayısal değişkenler arası korelasyon ısı haritası.

5. Modelleme

Problem bir regresyon problemi olarak tanımlandığından, sürekli hedef değişkeni tahmin etmeye uygun olan Lineer Regresyon ve Random Forest algoritmaları seçilmiş ve karşılaştırmalı olarak değerlendirilmiştir. Modelleme, hedef değişken ($\log_market_value$) ve metinsel mevki alanı dışarıda bırakılarak 15 öznitelik üzerinde gerçekleştirilmiştir. Veri kümesi %80 eğitim ve %20 test olacak biçimde, tekrarlanabilirliği güvence altına almak için sabit bir rastgelelik ($random_state = 42$) ile ayrılmıştır.

5.1. Lineer Regresyon

İlk yaklaşım olarak Lineer Regresyon seçilmiştir. Bu modelin tercih edilmesinin temel gerekçesi, yorumlanabilirliği yüksek bir temel başarı çizgisi (baseline) oluşturması ve öznitelikler ile hedef değişken arasındaki doğrusal ilişkilerin ne ölçüde açıklayıcı olduğunu test etmeye olanak tanımasıdır. Lineer regresyon, değişkenler arasındaki bağıntıların doğrusal olduğu varsayımına

dayandığından, problemin doğrusal bileşeninin gücünü ölçmek için uygun bir başlangıç noktası olduğu düşünülmüştür.

5.2. Random Forest

İkinci yaklaşım olarak, çok sayıda karar ağacının topluluk yöntemiyle birleştirildiği Random Forest algoritması kullanılmıştır. Bu modelin seçilmesinin gerekçesi, piyasa değeri ile öznelilikler arasındaki ilişkilerin büyük olasılıkla doğrusal olmaması ve değişkenler arası etkileşimlerin önem taşımasıdır. Random Forest, doğrusal olmayan örüntüleri ve değişken etkileşimlerini öğrenebilmesi, aykırı değerlere karşı görece dayanıklı olması ve öznelilik önemi çıktısı üreterek yorumlanabilirlik sağlaması nedeniyle bu problem için güçlü bir aday olarak değerlendirilmiştir. Her iki model de hem genel veri kümesi üzerinde hem de mevkilere göre ayrı ayrı eğitilerek mevki bazlı tahmin performansları da incelenmiştir.

6. Değerlendirme

Modellerin başarısı, regresyon problemleri için uygun olan Ortalama Mutlak Hata (MAE), Kök Ortalama Kare Hata (RMSE) ve Belirleme Katsayısı (R^2) metrikleriyle değerlendirilmiştir. Modellerin genellenebilirliğini denetlemek amacıyla ayrıca 5 katlı çapraz doğrulama (5-fold cross-validation) RMSE değerleri hesaplanmıştır. Tüm hata metrikleri logaritmik ölçekteki hedef değişken üzerinden raporlanmıştır.

6.1. Genel Model Karşılaştırması

Model	MAE	RMSE	R^2	CV RMSE	CV Std
Lineer Regresyon	0.8195	1.0300	0.4980	1.0405	0.0097
Random Forest	0.6120	0.7832	0.7098	0.7993	0.0100

Yukarıdaki tabloda Doğrusal Regresyon ve Random Forest modellerinin genel veri kümesi üzerindeki performansı karşılaştırmalı olarak sunulmuştur. Sonuçlar, Random Forest modelinin Lineer Regresyon'a kıyasla tüm metriklerde belirgin biçimde üstün olduğunu göstermektedir. Random Forest, hedef değişkendeki varyansın yaklaşık %71'ini açıklarken ($R^2 = 0,7098$), Doğrusal Regresyon yaklaşık %50'sini ($R^2 = 0,4980$) açıklayabilmiştir.

Random Forest, hem MAE hem de RMSE değerlerinde Lineer Regresyon'un altında kalmıştır, Bu da daha düşük hata anlamına gelir.

Modellerin çapraz doğrulama sonuçlarında da Random Forest RMSE değeri, Lineer Regresyon RMSE değerinden düşüktür ve tek seferlik test sonuçlarıyla tutarlıdır. Her iki modelin de standart sapmalarının düşük ve birbirine yakın olması modellerin farklı veri alt kümelerinde kararlı sonuçlar ürettiğini göstermektedir.

Genel olarak bu sonuçlar, piyasa değeri ile öznelilikler arasındaki ilişkinin önemli ölçüde doğrusal olmadığını ve değişken etkileşimleri ile doğrusal olmayan örüntüler içerdiğini ortaya

koymaktadır. Bu nedenle, doğrusal olmayan yapıları ve değişkenler arası etkileşimleri öğrenebilen Random Forest, bu problem için daha uygun bir model olarak öne çıkmaktadır.

6.2. Mevki Bazlı Model Performansı

Mevkilere göre eğitilen modellerin sonuçları aşağıda sunulmuştur. Tüm mevkilerde Random Forest, Lineer Regresyon'a kıyasla daha yüksek R^2 ve daha düşük hata değerleri üretmiştir.


Mevki	LR RMSE	RF RMSE	LR MAE	RF MAE	LR R^2	RF R^2	LR CV RMSE	RF CV RMSE
Forvet (Attack)	1,0198	0,8325	0,8185	0,6460	0,4967	0,6646	1,0577	0,8599
Defans (Defender)	1,0165	0,8014	0,8116	0,6280	0,4774	0,6752	1,0234	0,8125
Kaleci (Goalkeeper)	1,0330	0,7716	0,7938	0,6134	0,3818	0,6550	1,0156	0,8366
Orta Saha (Midfield)	1,0610	0,8339	0,8464	0,6509	0,5209	0,7040	1,0342	0,8492

Random Forest'ın en yüksek başarısı orta saha oyuncularında ($R^2 = 0,7040$), en düşük başarısı ise kalecilerde ($R^2 = 0,6550$) gözlemlenmiştir. Kaleci modelindeki görece düşük açıklayıcılık, kalecilerin piyasa değerinin gol ve asist gibi standart hücum istatistikleriyle açıklanamamasından, bu mevkiye özgü performans göstergelerinin (kurtuluş, kalesini gole kapatma vb.) veri kümesinde bulunmamasından kaynaklanıyor olabilir. Bu durum özellikle doğrusal modelde belirginleşmekte; Doğrusal Regresyon kalecilerde yalnızca 0,3818 R^2 ile dört mevki içindeki en düşük performansını vermektedir.

Doğrusal Regresyon tarafında açıklayıcılık dört mevkide 0,38–0,52 aralığında dağılırken, Random Forest 0,66–0,70 gibi hem daha yüksek hem de daha dar bir bantta toplanmaktadır. Modeller arasındaki bu belirgin R^2 farkı, piyasa değeri ile öznelilikler arasındaki ilişkinin tüm mevkilerde önemli ölçüde doğrusal olmadığını ve değişken etkileşimleri içerdiğini doğrulamaktadır. Hata metrikleri de bu bulguyu desteklemekte, Random Forest tüm mevkilerde hem RMSE hem de MAE bakımından doğrusal modelin belirgin biçimde altında (daha düşük) hata üretmektedir. Genel olarak mevki bazlı modeller, genel modele ($RF R^2 = 0,71$) yakın bir performans sergilemiş; bu da yaş ve toplam maç gibi mevkiden bağımsız değişkenlerin tüm pozisyonlarda baskın açıklayıcı güce sahip olduğunu desteklemektedir.

6.3. Mevki Bazlı Karşılaştırma


Mevki bazlı R^2 grafiği, dört mevki için Lineer Regresyon ve Random Forest modellerinin açıklayıcılık düzeylerini karşılaştırmalı olarak sunmakta ve Random Forest'ın tüm mevkilerdeki tutarlı üstünlüğünü görselleştirmektedir.



Grafik 5: Mevkilere göre model R^2 karşılaştırması.

6.4. Gerçek ve Tahmin Karşılaştırması

Gerçek–tahmin saçılım grafiği, her iki model için test kümesindeki gerçek değerler ile tahmin edilen değerleri kırmızı kesikli ideal doğru etrafında karşılaştırmaktadır. Random Forest tahminlerinin ideal doğru çevresinde daha dar bir saçılım sergilemesi, bu modelin daha yüksek tahmin doğruluğunu görsel olarak desteklemektedir.




Grafik 6: Gerçek ve tahmin edilen değerlerin karşılaştırması (sol: Doğrusal Regresyon, sağ: Random Forest).

6.5. Öznitelik Önemi

Öznitelik önemi grafiği, Random Forest modelinin tahminlerinde hangi değişkenlerin daha belirleyici olduğunu sıralamaktadır. Buna göre yaş ve toplam maç sayısı açık ara en önemli iki değişkendir; bunları oyuncunun bulunduğu lig (player_club_domestic_competition_id) izlemektedir. Bu bulgu, oyuncu değerinin yalnızca bireysel performansla değil, oynanan lig


ekosisteminin ekonomik gücüyle de yakından ilişkili olduğunu göstermesi bakımından dikkat çekicidir.



Grafik 7: Random Forest modeline göre öznelik önem sıralaması

6.6. Hata Analizi

Artık (residual) dağılım grafiği, tahmin hatalarının sıfır çizgisi etrafındaki dağılımını göstermektedir. Artıkların sıfır çevresinde belirgin bir örüntü olmaksızın dağılması model varsayımları açısından olumlu kabul edilirken, Random Forest’ın artıklarının daha dar bir bant içinde yoğunlaşması daha düşük hatayı yansıtmaktadır.



Grafik 8: Modellerin artık (hata) dağılımları

6.7. Tahmin Yorumu

Modellerin başarımını yalnızca toplu metrikler (R^2 , RMSE, MAE) üzerinden değil, tekil tahminler düzeyinde de değerlendirmek amacıyla test kümesinden seçilen örnekler incelenmiştir. Modeller hedef değişkeni logaritmik ölçekte tahmin ettiğinden, sonuçlar expm1 ters dönüşümüyle yeniden Euro cinsine çevrilerek gerçek piyasa değerleriyle karşılaştırılmıştır.

Genel model çıktıları, düşük ve orta değer bandındaki (yaklaşık 100.000–700.000 €) oyunculara her iki modelin de makul bir yakınlık yakaladığını göstermektedir. Örneğin gerçek değeri 700.000 € olan bir oyuncu için tahminler 549.000–566.000 € aralığında kalmış, doğru büyüklük mertebesi tutturulmuştur. Buna karşılık bazı düşük değerli oyunculara modeller iki ila üç kat aşırı tahmin (overestimation) üretebilmektedir; bu durum, bireysel istatistikleri görece güçlü olduğu hâlde piyasa değeri düşük kalmış oyuncuların varlığına işaret etmektedir.

En belirgin örüntü, yüksek değerli oyunculara gözlemlenen sistematik düşük tahmindir (underestimation). Gerçek değeri 60.000.000 € olan bir oyuncu için Lineer Regresyon yalnızca 3.181.473 €, Random Forest ise 14.915.111 € tahmin etmiştir; her iki model de gerçek değer in oldukça altında kalmıştır. Bu davranışın temel nedeni, hedef değişkenin sağa çarpık dağılımı ve eğitim verisinde çok yüksek değerli oyuncuların sayıca az olmasıdır. Modeller, istatistiksel olarak nadir gözlemlenen bu uç değerleri ortalamaya doğru çekme eğilimindedir.

Gerçek (€)	LR Tahmini (€)	RF Tahmini (€)
700,000	565,786	548,834
2,000,000	214,528	201,742
60,000,000	3,181,473	14,915,111

Mevki bazlı tahminlerde de benzer bir tablo ortaya çıkmaktadır. Defans ve forvet oyuncularında düşük-orta değerli örnekler görece isabetli tahmin edilirken, yüksek değerli örneklerde yine düşük tahmin eğilimi sürmektedir.

Sonuç olarak tahmin incelemesi, modellerin genel piyasa eğilimini çoğunlukla başarıyla yakaladığını ancak özellikle uç değerlerde ve istatistikleriyle çelişen özel durumlarda sapma gösterebildiğini ortaya koymaktadır. Bu bulgu, modelin toplamda güçlü bir açıklayıcılığa sahip olmasına rağmen, bireysel uç noktalarda mükemmel olmaktan uzak olduğunu göstermektedir. Random Forest, bu uç durumlarda bile doğrusal modele kıyasla daha tutarlı ve gerçeğe yakın tahminler üretmiştir.

7. Arayüz

Geliştirilen modeller ile yapılan tahminleri daha iyi gözlemleyebilmek adına Streamlit kütüphanesi ile bir web arayüzü geliştirilmiştir. Bu arayüz, eğitim aşamasında serileştirilen model, kodlayıcı (encoder) ve ölçekleyici (scaler) nesnelerini yükleyerek, kullanıcının girdiği futbolcu bilgilerini gerçek zamanlı olarak bir piyasa değeri tahminine dönüştürmektedir.

Arayüzün giriş bölümünde kullanıcı, futbolcuya ait kategorik bilgileri açılır listelerden seçmekte; yaş, boy, toplam maç, toplam gol, toplam asist, maç başına dakika ile sarı ve kırmızı kart sayısı gibi sayısal değişkenleri ise sayı giriş alanları aracılığıyla girmektedir. Bu sayede, modelin eğitiminde kullanılan tüm öznitelikler kullanıcı tarafından sağlanabilmektedir.

"Tahmin Et" düğmesine basıldığında, girilen veriler doğrultusunda bir tahmin üretilir ve çıktı bölümünde gösterilir.

The screenshot shows a web browser window with the URL 'localhost'. The page title is 'Futbolcu Piyasa Değeri Tahmini'. Below the title, there is a subtitle 'Futbolcu bilgilerine göre tahmini piyasa değerini hesaplar.' and a prompt 'Lütfen futbolcunun kariyer istatistiklerini giriniz.' The form contains several input fields: 'Mevki' (Attack), 'Alt Mevki' (Attacking Midfield), 'Ayak' (both), 'Ülke' (Afghanistan), 'Lig' (A1), 'Yaş' (24), and 'Boy (cm)' (180). Each field has a dropdown arrow or a plus/minus button.

Görsel 1: Arayüz örneği - Girdi

The screenshot shows the same web browser window after clicking the 'Tahmin Et' button. The output section displays the predicted market value for the player. The 'Genel Model Sonuçları' section shows three values: Linear Regression (€3,628,579), Random Forest (€3,100,533), and Ortalama (€3,364,556). The 'Mevki Bazlı Model Sonuçları (Attack)' section shows two values: LR (Mevki) (€3,397,971) and RF (Mevki) (€1,757,995). Below these, there is a table titled 'Modelle gönderilen veri' with the following data:

	age	height_in_cm	total_goals	total_assists	total_matches	total_yellow_cards	total_red
0	-1.0875	-0.3307	0.146	-0.0676	-0.2801	-0.4949	

At the bottom, a note states: 'İstatistikler 22 Mart 2026 tarihine kadar olan maçları kapsamaktadır.'

Görsel 2: Arayüz örneği - Çıktı

8. Yapay Zekâ ve Etik Beyanı

Bu projenin tüm aşamaları (problem tanımı, veri toplama ve birleştirme, ön işleme, modelleme kararları ve sonuçların yorumlanması) proje ekibi tarafından gerçekleştirilmiştir. Süreç boyunca Claude adlı yapay zekâ aracından yardımcı bir araç olarak yararlanılmıştır; bu yardım, kodun kontrol edilmesi ve zorlandığımız yerlerde yönlendirme amaçlı soruların sorulmasıyla sınırlı kalmıştır. Projeye ilişkin tüm teknik kararlar ve nihai içerik ekibin sorumluluğundadır.

9. Kaynakça

Cariboo, D. (2026). Football Data from Transfermarkt

<https://www.kaggle.com/datasets/davidcariboo/player-scores>